

MODÈLE PRÉDICTIF DE LA CONSOMMATION D'ÉNERGIE DES BÂTIMENTS DE SEATTLE



PRÉSENTATION DE LA MISSION

L'objectif de la mission est de développer un modèle Machine Learning de prédiction de la consommation en énergie d'un bâtiment de la ville de Seattle.

- Nettoyage et adaptation du jeu de données
- Apprentissage et sélection du modèle
- Optimisation des paramètres du modèle

Le jeu de données pour cette étude consiste en un fichier CSV "2016_Building_Energy_Benchmarking" disponible sur le portail [City of Seattle Open Data](#).

ANALYSE ET OPTIMISATION DES DONNÉES

SUPPRESSION DES VARIABLES NON PERTINENTES

General

OSEBuildingID
DataYear
BuildingType
PrimaryPropertyType
PropertyName
YearBuilt
DefaultData
Comments
ComplianceStatus
Outlier

Structure

NumberOfBuildings
NumberOfFloors
PropertyGFATotal
PropertyGFAParking
PropertyGFABuilding(s)
ListOfAllPropertyUseTypes
LargestPropertyUseType
LargestPropertyUseTypeGFA
SecondLargestPropertyUseType
SecondLargestPropertyUseTypeGFA
ThirdLargestPropertyUseType
ThirdLargestPropertyUseTypeGFA

Energy

YearsENERGYSTARCertified
ENERGYSTARScore
SiteEUI(kBtu/sf)
SiteEUIWN(kBtu/sf)
SourceEUI(kBtu/sf)
SourceEUIWN(kBtu/sf)
SiteEnergyUse(kBtu)
SiteEnergyUseWN(kBtu)
SteamUse(kBtu)
Electricity(kWh)
Electricity(kBtu)
NaturalGas(therms)
NaturalGas(kBtu)

Emissions

TotalGHGEmissions
GHGEmissionsIntensity

Localisation

Address
City
State
ZipCode
TaxParcelIdentificationNumber
CouncilDistrictCode
Neighborhood
Latitude
Longitude

Suppressions:

Pas/peu d'information

Texte peu exploitable

Valeur unique

Shape:

(3376, 46)

(3376, 33)

ANALYSE ET OPTIMISATION DES DONNÉES

SUPPRESSION DES VARIABLES À FORT TAUX DE MANQUANTS, BÂTIMENTS RÉSIDENTIELS,
BÂTIMENTS À DÉCLARATION NON CONFORME

General

BuildingType
PrimaryPropertyType
YearBuilt
ComplianceStatus

Localisation

CouncilDistrictCode
Neighborhood
Latitude
Longitude

Structure

NumberOfBuildings
NumberOfFloors
PropertyGFABuilding(s)
ListOfAllPropertyUseTypes
LargestPropertyUseType
LargestPropertyUseTypeGFA
SecondLargestPropertyUseType
SecondLargestPropertyUseTypeGFA
ThirdLargestPropertyUseType
ThirdLargestPropertyUseTypeGFA

Energy

YearsENERGYSTARCertified
ENERGYSTARScore
SiteEUI(kBtu/sf)
SiteEUIWN(kBtu/sf)
SourceEUI(kBtu/sf)
SourceEUIWN(kBtu/sf)
SiteEnergyUse(kBtu)
SiteEnergyUseWN(kBtu)
SteamUse(kBtu)
Electricity(kWh)
Electricity(kBtu)
NaturalGas(therms)
NaturalGas(kBtu)

Emissions

TotalGHGEmissions
GHGEmissionsIntensity

Suppressions:

Bâtiments résidentiels: BuildingType = 'Multifamily xx'

Taux de manquants > 1/3

Déclarations non conformes: ComplianceStatus <> 'Compliant'

Shape:

(3376, 33)

(1668, 33)

(1668, 27)

(1548, 26)

ANALYSE ET OPTIMISATION DES DONNÉES

VARIABLES ÉNERGÉTIQUES NON EXPRIMÉES EN kBtu, VARIABLES DE LOCALISATION CORRÉLÉES,
VARIABLES ÉNERGÉTIQUES BRUTES VS WN, SÉLECTION DE LA CIBLE,

General

BuildingType
PrimaryPropertyType
YearBuilt

Localisation

CouncilDistrictCode
Neighborhood
Latitude
Longitude

Structure

NumberOfBuildings
NumberOfFloors
PropertyGFABuilding(s)
ListOfAllPropertyUseTypes
LargestPropertyUseType
LargestPropertyUseTypeGFA

Energy

SiteEUI(kBtu/sf)
SiteEUIWN(kBtu/sf)
SourceEUI(kBtu/sf)
SourceEUIWN(kBtu/sf)
SiteEnergyUse(kBtu)
SiteEnergyUseWN(kBtu)
SteamUse(kBtu)
Electricity(kWh)
Electricity(kBtu)
NaturalGas(therms)
NaturalGas(kBtu)

Emissions

TotalGHGEmissions
GHGEmissionsIntensity

Suppressions:

Variables énergétiques non exprimées en kBtu

Variables de localisation corrélées aux coordonnées spatiales

Variables énergétiques brutes corrélées à la version WN

Variables énergétiques non retenues pour la cible

Variables d'émission considérées comme risque de fuite

Shape:

(1548, 26)

(1548, 24)

(1548, 22)

(1548, 19)

(1548, 17)

(1548, 15)

ANALYSE ET OPTIMISATION DES DONNÉES

MANQUANTS RÉSIDUELS

General

BuildingType
PrimaryPropertyType
YearBuilt

Localisation

Latitude
Longitude

Structure

NumberofBuildings
NumberofFloors
PropertyGFABuilding(s)
ListOfAllPropertyUseTypes
LargestPropertyUseType
LargestPropertyUseTypeGFA

Energy

SiteEUIWN(kBtu/sf) - Cible
SteamUse(kBtu)
Electricity(kBtu)
NaturalGas(kBtu)

	nb_missing
LargestPropertyUseType	4
LargestPropertyUseTypeGFA	4
SiteEUIWN(kBtu/sf)	1


Valeurs estimées
par analogie

Bâtiment supprimé

Shape:
(1548, 15)
(1547, 15)

ANALYSE ET OPTIMISATION DES DONNÉES

FEATURE ENGINEERING – VARIABLES CATÉGORIELLES OU TEXTE



ANALYSE ET OPTIMISATION DES DONNÉES

FEATURE ENGINEERING – VARIABLES NUMÉRIQUES

BuildingAge

Remplacer par l'âge
de la propriété

General

BuildingType
PrimaryPropertyType
YearBuilt

Localisation

Latitude
Longitude

Ajouter la distance
au centre-ville en km

DistToDowntown_km

Structure

NumberOfBuildings
NumberOfFloors
PropertyGFABuilding(s)
NbPropertyUses
LargestPropertyUseType
LargestPropertyUseTypeGFA

Energy

SiteEUIWN(kBtu/sf) - Cible
SteamUse(kBtu)
Electricity(kBtu)
NaturalGas(kBtu)



Remplacer par des booléens pour
représenter le mix énergétique (float > int).
0 – Ne consomme pas le type d'énergie
1 – Consomme le type d'énergie

UseSteamUse
UseElectricity
UseNaturalGas

Shape:
(1547, 15)
(1547, 16)

ANALYSE ET OPTIMISATION DES DONNÉES

DISTRIBUTION DE LA CIBLE



La distribution brute montre une dissymétrie à gauche.


La distribution log est plus symétrique et montre des valeurs à 0.

Les valeurs à 0 sont supprimées.

Shape:
(1547, 16)
(1536, 16)

ANALYSE ET OPTIMISATION DES DONNÉES

MATRICE DE CORRÉLATION DES VARIABLES NUMÉRIQUES RESTANTES




Les variables PropertyGFABuilding(s) et LargestPropertyUseTypeGFA sont corrélées.

LargestPropertyUseTypeGFA est supprimée

Shape:
(1536, 16)
(1536, 15)

APPRENTISSAGE ET MEILLEUR MODÈLE

PRÉPROCESSEUR DE FORMATAGE DES VARIABLES



APPRENTISSAGE ET MEILLEUR MODÈLE

APPRENTISSAGE ET SCORING

Validation croisée en 5 folds (5-fold cross-validation).

Modèle	RMSE Root Mean Squared Error	MAE Mean Absolute Error	R ² Coefficient de détermination
Dummy	78,6	43,0	-0,084
LinearRegression	62,2	36,6	0,318
SVR	76,3	40,6	-0,020
RandomForest	61,2	36,9	0,336
GradientBoosting	61,5	36,3	0,327

RandomForest obtient le meilleur score R².

APPRENTISSAGE ET MEILLEUR MODÈLE

OPTIMISATION DU MODÈLE

```
"model__n_estimators": [100, 200, 300, 400],  
"model__max_depth": [None, 10, 20],  
"model__min_samples_leaf": [1, 2, 3, 5],  
"model__min_samples_split": [2, 5, 10],  
"model__max_features": ["sqrt", 0.5],
```

Nombre d'arbres dans la forêt

Profondeur maximale d'un arbre

Nombre minimum d'observations dans une feuille

Nombre minimum d'observations pour diviser un nœud

Nombre de variables candidates pour diviser un arbre




GridSearch sur RandomForest (288 combinaisons, 1440 apprentissages)

```
"model__n_estimators": [300],  
"model__max_depth": [None],  
"model__min_samples_leaf": [1],  
"model__min_samples_split": [2],  
"model__max_features": ["sqrt"],
```

Meilleur R2: 0.383

APPRENTISSAGE ET MEILLEUR MODÈLE

FEATURE IMPORTANCE PAR SHAP



L'analyse SHAP montre que la consommation énergétique des bâtiments dépend principalement de trois facteurs : le type d'activité du bâtiment, le mix énergétique utilisé et les caractéristiques structurelles du bâtiment comme son âge et sa taille.